
**FIAP - FACULDADE DE INFORMATICA E ADMINISTRACAO
PAULISTA**

**CLASSIFICACAO DA QUALIDADE DE VINHOS COM
MACHINE LEARNING**

Tech Challenge - Fase 2

Relatório Executivo

Caieiras - SP

2026

Sumário

1. Introdução	4
2. Objetivo	5
2.1 Objetivo Geral	5
2.2 Objetivos Específicos	5
3. Metodologia	6
3.1 Compreensão do Problema e do Dataset	6
3.2 Análise Exploratória de Dados (EDA)	6
3.2.1 Distribuição das <i>Features</i>	6
3.2.2 Comparação entre Classes por <i>Boxplots</i>	7
3.2.3 Análise de Correlação (Pearson)	7
3.2.4 Teste Estatístico <i>Mann-Whitney U</i>	7
3.3 Pré-processamento de Dados	7
3.3.1 Feature Engineering	8
3.3.2 Tratamento do Desbalanceamento	8
3.4 Desenvolvimento e Avaliação dos Modelos	8
3.4.1 Seleção dos Modelos	8
3.4.2 Métricas de Avaliação e Justificativas	9
4. Resultados	10
4.1 Análise Exploratória dos Dados (EDA)	10
4.1.1 Distribuição da Variável Alvo e Binarização	10
4.1.2 Distribuição das Features e Identificação de Assimetria	11
4.1.3 Comparação de Distribuições entre Classes	13
4.1.4 Mapa de Correlação de Pearson	15
4.1.5 Ranking de Correlação com Quality	16
4.2 Resultado do Pré-processamento	17
4.3 Desempenho dos Modelos no Conjunto de Teste	18

4.3.1	Curvas ROC e Precision-Recall	18
4.3.2	Análise das Matrizes de Confusão	19
4.3.3	Resultado Global: Acertos vs Erros	20
4.4	Importância das Features.....	21
4.4.1	<i>Gini Importance versus Permutation Importance</i>	21
5.	Conclusão.....	24
5.1	Síntese dos Resultados.....	24
5.2	Decisão sobre o Modelo Vencedor	24
5.3	Limitações e Próximos Passos	25
6.	Aplicação Prática	26
6.1	Cenários de Uso na Indústria Vitivinícola	26
	Controle de Qualidade em Linha de Produção	26
	Segmentação e Precificação de Produtos	26
	Formulação e Reprodução de Lotes <i>Premium</i>	26
6.2	Impacto Potencial e Retorno sobre Investimento.....	26
6.3	<i>Roadmap</i> de Implementação.....	27
6.4	Salvaguardas no Uso de Modelos Preditivos	27
	Referencias	28

1. Introdução

A indústria vitivinícola movimenta bilhões de dólares por ano e tem na qualidade do produto um de seus principais diferenciais competitivos. Tradicionalmente, a avaliação da qualidade de um vinho é realizada por especialistas sensoriais, cujas análises consideram aspectos como aroma, sabor, acidez, corpo e equilíbrio. **Esse processo, ainda que refinado, e subjetivo, demorado e dependente da disponibilidade de especialistas treinados**, o que o torna um gargalo no processo produtivo de vinícolas em escala.

Com o avanço das técnicas de ciência de dados e aprendizado de máquina, tornou-se possível explorar padrões objetivos nos dados físico-químicos de cada amostra de vinho, obtidos durante ou logo após a produção, para prever a qualidade final antes mesmo da avaliação sensorial. **Essa abordagem oferece aos produtores uma ferramenta de apoio a tomada de decisão que pode antecipar ajustes no processo produtivo, reduzir o volume de rejeição pós-avaliação e contribuir para a padronização da qualidade ao longo das safras.**

O presente relatório documenta o desenvolvimento de uma pipeline completa de modelagem preditiva aplicada ao *Wine Quality Dataset (WineQT)*, publicado no *Kaggle*, que pode ser consultado via *GitHub*: [Classificacao_qualidade_dos_vinhos/WineQT.csv](#)

O trabalho contemplou todas as etapas do ciclo de vida de um projeto de dados, iniciando com a compreensão do problema de negócio, análise exploratória dos dados, pré-processamento e engenharia de atributos, treinamento e avaliação de múltiplos modelos de classificação, e interpretação dos resultados sob uma perspectiva de aplicabilidade prática na indústria.

2. Objetivo

2.1 Objetivo Geral

Desenvolver um modelo de classificação supervisionada capaz de prever, a partir de variáveis físico-químicas mensuradas objetivamente, se um **vinho será classificado como de alta qualidade** (nota igual ou superior a 7 na escala sensorial) **ou de baixa e média qualidade** (nota inferior a 7).

2.2 Objetivos Específicos

- A. Realizar análise exploratória dos dados (EDA) para compreender distribuições, correlações e o grau de balanceamento das classes.
- B. Desenvolver um pipeline de pré-processamento robusto, incluindo tratamento de assimetria, normalização resistente a outliers e criação de novas *features* com racional enológico.
- C. Treinar e avaliar comparativamente três modelos de classificação: Regressão Logística (baseline linear), Random Forest (*ensemble por bagging*) e Gradient Boosting (*ensemble por boosting*).
- D. Selecionar o modelo mais adequado com base em métricas apropriadas para o contexto de classes desbalanceadas.
- E. Identificar as variáveis físico-químicas de maior influência na predição da qualidade, gerando insights acionáveis para o processo produtivo.

3. Metodologia

3.1 Compreensão do Problema e do Dataset

O *dataset WineQT* contém 1.143 amostras originais de vinho tinto português (Vinho Verde), com 11 variáveis físico-químicas e uma variável de qualidade atribuída por especialistas na escala inteira de 3 a 8. A primeira etapa consistiu em inspecionar o *dataset*, identificar e remover 125 registros duplicados exatos, **resultando em 1.018 amostras únicas para o estudo**. As variáveis do *dataset* e seus papéis no modelo estão descritos abaixo:

Variável	Tipo	Descrição	Papel
<i>fixed acidity</i>	Numérica continua	Acidez fixa (tartárica)	<i>Feature</i> preditora
<i>volatile acidity</i>	Numérica continua	Acidez volátil (acética)	<i>Feature</i> preditora
<i>citric acid</i>	Numérica continua	Ácido cítrico	<i>Feature</i> preditora
<i>residual sugar</i>	Numérica continua	Açúcar residual após fermentação	<i>Feature</i> preditora
<i>chlorides</i>	Numérica continua	Concentração de cloretos	<i>Feature</i> preditora
<i>free sulfur dioxide</i>	Numérica continua	SO ₂ livre (fracção ativa)	<i>Feature</i> preditora
<i>total sulfur dioxide</i>	Numérica continua	SO ₂ total	<i>Feature</i> preditora
<i>density</i>	Numérica continua	Densidade do líquido	<i>Feature</i> preditora
<i>pH</i>	Numérica continua	Nível de acidez global	<i>Feature</i> preditora
<i>sulphates</i>	Numérica continua	Sulfatos adicionados	<i>Feature</i> preditora
<i>alcohol</i>	Numérica continua	Teor alcoólico (% vol.)	<i>Feature</i> preditora
<i>quality</i>	Inteiro (3-8)	Nota sensorial dos especialistas	Variável alvo original
<i>quality_label</i>	Binário (0/1)	1 se <i>quality</i> $\geq$ 7; 0 caso contrário	Variável alvo do modelo

3.2 Análise Exploratória de Dados (EDA)

3.2.1 Distribuição das *Features*

Para cada uma das 11 *features* originais, foram gerados histogramas com sobreposição de curva KDE (*Kernel Density Estimation*). O KDE é uma estimativa suavizada da função densidade de probabilidade, que permite identificar o formato da distribuição sem depender da escolha do número de intervalos do histograma. A assimetria (*skewness*) foi calculada para cada *feature*, **classificando-as em três categorias: assimetria baixa ($|skew|$**

inferior a 0,5), assimetria moderada ($|skew|$ entre 0,5 e 1,0) e assimetria severa ($|skew|$ superior a 1,0).

3.2.2 Comparação entre Classes por *Boxplots*

Boxplots lado a lado para cada *feature*, separando vinhos de Alta Qualidade e Baixa/Média Qualidade, foram utilizados para identificar quais atributos apresentam maior poder discriminante visualmente. O *boxplot* exibe a mediana (linha central), o intervalo interquartil (caixa de 25% a 75%), os bigodes (1,5x IQR) e pontos externos como outliers.

3.2.3 Análise de Correlação (Pearson)

A correlação de Pearson foi calculada entre todas as *features* e a variável de qualidade, gerando um mapa de calor completo. O objetivo dual desta análise foi **identificar as *features* mais correlacionadas com a qualidade e detectar pares de *features* altamente correlacionadas entre si, com risco de multicolinearidade.**

3.2.4 Teste Estatístico *Mann-Whitney U*

Para validar estatisticamente se as diferenças visuais entre classes observadas nos *boxplots* são genuínas, foi aplicado o teste de *Mann-Whitney U* para cada *feature*. Este teste não-paramétrico foi escolhido em preferência ao teste t de *Student* porque não pressupõe normalidade nas distribuições, requisito violado pelas *features* assimétricas identificadas. O *effect size* foi calculado complementarmente para mensurar a magnitude prática da diferença.

3.3 Pré-processamento de Dados

A pipeline de pré-processamento foi estruturada na seguinte sequência lógica, cujo ordenamento é justificado a seguir:

Etapas	Técnica	Justificativa
1	Transformação log1p nas <i>features</i> assimétricas	Reduz assimetria severa , estabiliza variância e melhora a qualidade das amostras sintéticas geradas pelo SMOTE
2	<i>Feature Engineering</i> (3 novas variáveis)	Captura relações entre pares de atributos com significado enológico que as <i>features</i> individuais não expressam
3	Normalização com <i>RobustScaler</i>	Padroniza a escala usando mediana e IQR em vez de média e desvio padrão, sendo resistente a outliers presentes nos dados
4	Divisão treino/teste (80/20) estratificada	Garante que a proporção de classes no conjunto de teste reflita a proporção original (86:14), evitando avaliações enviesadas
5	SMOTE via <i>ImbPipeline</i> na validação cruzada	Balanceia as classes apenas no conjunto de treino de cada <i>fold</i> , evitando <i>data leakage</i> e produção de métricas otimistas

3.3.1 Feature Engineering

Três novas features foram criadas com racional enológico direto, calculadas após a transformação log1p dos componentes para evitar que a assimetria se propague para as razões:

- ***acid_ratio* = *fixed acidity* / (*volatile acidity* + 0.001)**: captura o equilíbrio entre acidez estrutural e acidez acética. Uma razão alta indica mais acidez benéfica e menos ácido acético, que em excesso compromete o sabor e a nota do vinho.
- ***so2_ratio* = *free SO2* / (*total SO2* + 0.001)**: mede a eficiência do dióxido de enxofre. O SO2 livre e a fração antimicrobiana ativa; quanto maior a proporção livre em relação ao total, mais eficiente e a conservação do vinho.
- ***alcohol_density* = *alcohol* / (*density* + 0.001)**: captura a relação entre fermentação e estrutura. Vinhos com alto teor alcoólico e baixa densidade indicam fermentação completa dos açúcares, característica associada a maior qualidade.

3.3.2 Tratamento do Desbalanceamento

O **dataset original apresenta distribuição marcadamente desbalanceada**, 86,5% das amostras são classificadas como Baixa/Média Qualidade e apenas 13,5% como Alta Qualidade, resultando em uma razão de aproximadamente 6:1 entre as classes. **Para contornar esse problema, foi utilizado o SMOTE** (*Synthetic Minority Oversampling Technique*) exclusivamente no conjunto de treino, dentro de cada *fold* da validação cruzada. O SMOTE gera amostras sintéticas da classe minoritária por interpolação linear entre vizinhos próximos no espaço de *features*.

3.4 Desenvolvimento e Avaliação dos Modelos

3.4.1 Seleção dos Modelos

Foram selecionados **três modelos com filosofias complementares e crescente complexidade de representação**, permitindo quantificar o ganho obtido ao abandonar a suposição de linearidade:

Modelo	Tipo	Vantagem Principal	Limitação
<i>Logistic Regression</i>	Linear (<i>baseline</i>)	Interpretável, convergência rápida, coeficientes com significado direto	Não captura relações não-lineares entre <i>features</i>
<i>Random Forest</i>	<i>Ensemble Bagging</i>	Robusto, reduz variância por média de árvores, tolerante a outliers	Menos interpretável, custo computacional maior
<i>Gradient Boosting</i>	<i>Ensemble Boosting</i>	Alta acurácia, aprende iterativamente sobre os resíduos dos modelos anteriores	Sensível a hiper parâmetros, risco de <i>overfitting</i> sem regularização

3.4.2 Métricas de Avaliação e Justificativas

A escolha das métricas de avaliação depende da natureza do problema. Em classificações binárias com classes desbalanceadas, a acurácia global pode ser enganosa. **Um modelo que sempre prevê a classe majoritária alcança 87% de acerto sem aprender nada sobre vinhos de alta qualidade.** Por isso foram selecionadas métricas mais adequadas, acompanhadas de suas justificativas.

Métrica	Fórmula Conceitual	Por que usar aqui
F1-Score	$2 \times (\text{Precisão} \times \text{Recall}) / (\text{Precisão} + \text{Recall})$	Principal métrica de seleção: média harmônica que penaliza modelos que falham em Precisão ou Recall
ROC-AUC	Area sob a curva TPR vs FPR	Avalia a qualidade do ranking probabilístico independente do limiar de decisão
PR-AUC	Area sob a curva Precisão vs Recall	Mais informativa que ROC-AUC com desbalanceamento; foca exclusivamente na classe minoritária
Recall	$VP / (VP + FN)$	Minimizar Falsos Negativos: vinho premium classificado como comum gera perda de receita
Precisão	$VP / (VP + FP)$	Minimizar Falsos Positivos: vinho comum classificado como premium gera insatisfação do cliente
<i>Accuracy</i>	$(VP + VN) / \text{Total}$	Incluída para referência; deve ser interpretada em conjunto com as demais métricas

Na matriz de confusão, o verdadeiro positivo ocorre quando o modelo prevê alta e o vinho realmente é alta, enquanto o verdadeiro negativo acontece quando prevê Baixa e o vinho realmente é Baixa. Já o falso positivo corresponde ao caso em que o modelo prevê alta, mas o vinho é Baixa, e o falso negativo aparece quando prevê Baixa, mas o vinho é alto. Entre esses erros, o falso negativo é o de maior impacto no negócio, pois significa que um vinho premium foi desclassificado, gerando perda de margem e subaproveitamento do produto.

Esse ponto conecta diretamente com a importância de métricas como Recall, que avaliam a capacidade do modelo de identificar corretamente os vinhos de alta qualidade, e com o F1-Score, que equilibra precisão e cobertura para reduzir esse tipo de falha.

4. Resultados

4.1 Análise Exploratória dos Dados (EDA)

4.1.1 Distribuição da Variável Alvo e Binarização

A Figura 1 apresenta, no painel esquerdo, a distribuição original das notas de qualidade do vinho e, no painel direito, a distribuição binária resultante da transformação segundo o critério definido no enunciado.




Figura 1: Distribuição original da variável qualidade e classificação binária resultante

A leitura do gráfico de barras mostra uma forte concentração nas notas 5 e 6, que juntas somam 433 e 409 amostras e representam cerca de 83% de todas as observações. **As notas extremas aparecem em proporção mínima, com apenas 6 amostras avaliadas como 3 e 15 como 8**, padrão comum em escalas sensoriais aplicadas por poucos avaliadores treinados. O gráfico de rosca reforça o desbalanceamento severo, **já que a classe Alta, definida por notas iguais ou superiores a 7, corresponde a apenas 13,5% do total, enquanto Baixa e Média concentram 86,5%**. Essa **assimetria de 6,4 para 1 é o principal desafio técnico**, pois modelos treinados sem tratamento específico tendem a ignorar a classe minoritária e entregar uma acurácia global elevada, porém enganosa.

Na prática, um modelo que classificasse todos os vinhos como Baixa ou Média já alcançaria 86,5% sem qualquer aprendizado real. Por esse motivo, foram escolhidas como

métricas primárias de avaliação a PR-AUC, cuja linha de base é 0,135, e o F1-Score, que equilibra precisão e cobertura para medir de forma mais justa o desempenho.

4.1.2 Distribuição das Features e Identificação de Assimetria

A Figura 2 apresenta os histogramas com curvas KDE para todas as 11 *features* originais, incluindo o valor de *skewness* (assimetria) calculado para cada uma. As linhas tracejadas indicam a média (vermelho) e a mediana (verde) de cada distribuição.

EDA — Distribuição das Features (histograma + KDE | skew = assimetria)




Figura 2: Distribuição das features originais com histograma, curva KDE e indicadores de média e mediana.

A análise dos gráficos evidencia três perfis distintos de distribuição. O primeiro perfil engloba *features* aproximadamente **simétricas**: *density* ($skew = 0,09$), pH ($skew = 0,26$) e *citric acid* ($skew = 0,37$) apresentam distribuições próximas da normal, com média e mediana muito próximas. Essas *features* não requerem transformação antes da modelagem. O segundo perfil inclui *features* **com assimetria moderada a alta**: *volatile acidity* ($skew = 0,72$), *alcohol* ($skew = 0,85$) e *fixed acidity* ($skew = 1,04$) mostram caudas a direita mais longas, com média maior que a mediana, indicando presença de valores extremos elevados.

O terceiro perfil, mas crítico, agrupa *features* de **assimetria severa**: *residual sugar* ($skew = 4,35$), *chlorides* ($skew = 5,93$), *total sulfur dioxide* ($skew = 1,68$), *free sulfur dioxide* ($skew = 1,17$) e *sulphates* ($skew = 2,42$). Nessas *features*, a massa das amostras se concentra em valores baixos enquanto um pequeno número de observações atinge valores muito elevados, o que distorceria tanto o normalizador quanto a interpolação do SMOTE. **A transformação log1p foi aplicada a todas essas seis features para comprimir as caudas longas e tornar as distribuições mais simétricas antes do pré-processamento.**

4.1.3 Comparação de Distribuições entre Classes

A Figura 3 apresenta *boxplots* lado a lado para cada *feature*, comparando as distribuições das classes Baixa/Média e Alta. Essa visualização permite identificar, de forma intuitiva, quais *features* separam melhor as duas classes.

EDA — Boxplots por Classe
(pontos = outliers pelo método IQR)




Figura 3: Boxplots por classe para todas as 11 features

O gráfico de *alcohol* apresenta a separação mais expressiva, a caixa da classe Alta está claramente deslocada para cima em relação a da classe Baixa/Média, com Mediana em torno de 11,5% vol. contra aproximadamente 10% vol. Essa separação, praticamente sem sobreposição entre as caixas, confirma o *alcohol* como o principal preditor positivo da qualidade.

Para *volatile acidity*, a relação é inversa, para vinhos de alta qualidade caixa deslocada está deslocada para baixo (menores valores de acidez acética), com Mediana em torno de 0,40 g/L contra 0,55 g/L na classe Baixa/Média. O excesso de acidez acética confere sabor de vinagre ao vinho, penalizando diretamente a nota dos especialistas.

Sulphates e *citric acid* também mostram separação positiva favorável a classe Alta, embora com sobreposição maior entre as caixas. Por outro lado, *residual sugar*, *density* e pH apresentam caixas praticamente idênticas entre as classes, antecipando seu baixo poder discriminante. A alta densidade de *outliers* observada especialmente em *chlorides* e *residual sugar* na classe Baixa/Média reforçar a decisão de usar o *RobustScaler* para normalização.

4.1.4 Mapa de Correlação de Pearson

A Figura 4 apresenta o mapa de calor de correlação de Pearson entre todas as variáveis do *dataset*.




Figura 4: Mapa de correlação de Pearson

A leitura do mapa revela dois pares de *features* com multicolinearidade expressiva. O par *free sulfur dioxide vs total sulfur dioxide* apresenta correlação positiva elevada, o que é esperado, já que o SO₂ livre é uma subfração do SO₂ total. O par *fixed acidity vs density* também exibe correlação positiva relevante, pois vinhos mais ácidos tendem a ser levemente mais densos. Embora esses pares possam causar instabilidade nos coeficientes da Regressão Logística, os modelos *ensemble* (*Random Forest* e *Gradient Boosting*) são naturalmente tolerantes a multicolinearidade pela aleatoriedade na seleção de *features* em cada árvore.

Em relação a *quality*, a correlação positiva mais intensa é com *alcohol* e a correlação negativa mais intensa é com *volatile acidity*. pH e *residual sugar* apresentam correlações próximas de zero com *quality*, confirmando o baixo poder discriminante já antecipado pelos *boxplots*.

4.1.5 Ranking de Correlação com Quality

A Figura 5 sintetiza as correlações de Pearson de todas as *features* com a variável *quality*, ordenado da mais negativa para a mais positiva.




Figura 5: Ranking de correlação de Pearson de cada *feature* com *quality*

O gráfico confirma e quantifica a hierarquia de relevância das *features*. O *alcohol* lidera com correlação positiva de 0,486, seguido de *sulphates* (0,258) e *citric acid* (0,242), todas acima do limiar de 0,20 considerado moderado. Na direção negativa, *volatile acidity* se destaca com -0,409, seguido de *density* (-0,185) e *total sulfur dioxide* (-0,182). As *features* *residual sugar* (0,023), pH (-0,058) e *free sulfur dioxide* (-0,071) ficaram próximas de zero e abaixo do limiar absoluto de 0,20, indicando fraca relação linear individual com a qualidade.

É importante notar que correlação linear é uma medida de relação monotônica linear entre duas variáveis. **Features com baixa correlação linear podem ainda ter contribuição preditiva em modelos não-lineares como *Random Forest* e *Gradient Boosting***, que capturam interações complexas entre múltiplas *features* simultaneamente. Por esse motivo, todas as *features* foram mantidas no modelo em vez de excluir aquelas com baixa correlação individual.

Para complementar a análise de Pearson, foi realizada uma comparação com o coeficiente de Spearman, que é baseado em ranks e captura relações monotônicas não-lineares sem assumir linearidade. A comparação entre os dois coeficientes revelou padrões relevantes: para *alcohol* e *volatile acidity*, Spearman e Pearson apresentaram valores muito próximos, indicando relação predominantemente linear — essas *features* são bem capturadas inclusive pela Regressão Logística. Já para *citric acid* e *sulphates*, o coeficiente de Spearman foi expressivamente maior que o de Pearson, evidenciando relações não-lineares que modelos lineares não capturam com eficiência. Para *residual sugar* e *free sulfur dioxide*, a diferença foi ainda mais acentuada, indicando que **outliers estavam distorcendo o coeficiente de Pearson** e subestimando a relação real com a qualidade. Essa análise reforça a justificativa para a escolha de modelos baseados em árvores (*Random Forest* e *Gradient Boosting*) sobre a Regressão Logística para este problema.

4.2 Resultado do Pré-processamento

Após a aplicação da transformação $\log_{1p}$ nas seis *features* assimétricas, a assimetria dessas distribuições foi significativamente reduzida, tornando-as mais adequadas para geração de amostras sintéticas pelo SMOTE e para o treinamento da Regressão Logística. As três novas *features* de engenharia (*acid_ratio*, *so2_ratio*, *alcohol_density*) foram calculadas sobre os dados transformados e validadas individualmente por correlação de *Spearman* com *quality_label* antes de serem incluídas no conjunto final de *features*.

O conjunto final de *features* do modelo totalizou 14 atributos: 5 *features* originais sem transformação (*citric acid*, *density*, *pH*, *volatile acidity*, *alcohol*), 6 versões $\log_{1p}$ (*fixed acidity*, *residual sugar*, *chlorides*, *free sulfur dioxide*, *total sulfur dioxide*, *sulphates*) e 3 *features engineered* (*acid_ratio*, *so2_ratio*, *alcohol_density*).

A normalização foi feita com *RobustScaler*, que calcula a Mediana e o IQR de cada *feature* e subtrai a Mediana, dividindo pelo IQR, em vez de usar média e desvio padrão como o *StandardScaler*, isso o torna resistente a outliers. **Após a normalização o conjunto foi dividido em 814 amostras para treino e 204 para teste** (divisão 80/20 estratificada). O

SMOTE, aplicado apenas no treino dentro de cada *fold* da validação cruzada, gerou conjuntos balanceados para cada iteração de treinamento.

4.3 Desempenho dos Modelos no Conjunto de Teste

Os resultados a seguir referem-se ao conjunto de teste, composto pelas 204 amostras não vistas durante o treinamento. Esta é a avaliação definitiva do desempenho real dos modelos em dados novos. A Figura 6 apresenta a comparação visual de todas as métricas para os três modelos, e a tabela abaixo complementa com os valores exatos.




Figura 6: Comparação das métricas de avaliação entre os três modelos no conjunto de teste

A leitura do gráfico revela de imediato que todos **os três modelos superam o baseline aleatório de PR-AUC** com grande margem, confirmando que as *features* físico-químicas contém informação preditiva real sobre a qualidade. A **Logistic Regression apresenta os menores valores em quase todas as métricas, exceto Recall, onde empata com o Random Forest**. O *Random Forest* lidera em PR-AUC (0,664) e Precisão (0,513), enquanto o *Gradient Boosting* supera em *Accuracy* (0,887), *F1-Score* (0,646) e *Recall* (0,778), além de empatar com *Random Forest* no ROC-AUC (0,907).

Modelo	<i>F1-Score</i>	PR-AUC	ROC-AUC	<i>Recall</i>	Precisão	<i>Accuracy</i>
<i>Logistic Regression</i>	0,488	0,469	0,886	0,741	0,364	0,794
<i>Random Forest</i>	0,606	0,664	0,907	0,741	0,513	0,873
<i>Gradient Boosting</i>	0,646	0,597	0,907	0,778	0,553	0,887

4.3.1 Curvas ROC e Precision-Recall

A Figura 7 apresenta as curvas ROC e *Precision-Recall* para os três modelos. As curvas ROC mostram o trade-off entre a Taxa de Verdadeiros Positivos e Falsos Positivos.




Figura 7: Curvas ROC e *Precision-Recall* respectivamente

As curvas ROC confirmam que *Random Forest* e *Gradient Boosting* são equivalentes em termos de capacidade de discriminação probabilística (AUC = 0,907 para ambos), ambos expressivamente superiores a *Logistic Regression* (AUC = 0,886). O formato das curvas, com rápida elevação na região de baixa taxa de falsos positivos, indica que os modelos *ensemble* conseguem identificar a maioria dos verdadeiros positivos sem acionar muitos alarmes falsos quando o limiar de decisão é ajustado adequadamente.

A curva *Precision-Recall* é um gráfico mais informativo neste contexto de desbalanceamento. O *Random Forest* apresenta a maior área sob a curva PR (PR-AUC = 0,664), o que significa que, para qualquer nível de Recall desejado, o *Random Forest* mante Precisão mais alta que os concorrentes. A curva do *Gradient Boosting* (PR-AUC = 0,597) cai mais rapidamente, indicando que, ao tentar identificar mais vinhos Alta (maior Recall), ele classifica proporcionalmente mais falsos positivos. A *Logistic Regression* (PR-AUC = 0,469) apresenta o pior desempenho nas regiões de Recall moderado a alto, refletindo a incapacidade do modelo linear de capturar as fronteiras não-lineares do problema.

4.3.2 Análise das Matrizes de Confusão

A Figura 8 apresenta as matrizes de confusão dos três modelos no conjunto de teste. Cada quadrante exibe a contagem absoluta e o percentual em relação ao total de 204 amostras.




Figura 8: Matrizes de confusão para os três modelos

A **Logistic Regression** apresentou 142 Verdadeiros Negativos (VN = 69,6%), 20 Verdadeiros Positivos (VP = 9,8%), 35 Falsos Positivos (FP = 17,2%) e 7 Falsos Negativos (FN = 3,4%). **Apesar de ter o menor número de FN entre os três modelos, ele compensou classificando erroneamente 35 vinhos comuns como premium**, resultando na Precisão mais baixa (0,364). Em termos práticos, isso significa que, de cada 55 vinhos que o modelo classificaria como Alta Qualidade, apenas 20 seriam realmente de alta qualidade.

O **Random Forest** apresentou 158 VN (77,5%), 20 VP (9,8%), 19 FP (9,3%) e 7 FN (3,4%). **Com apenas 19 alarmes falsos, o modelo equilibrou bem os dois tipos de erro, atingindo a melhor Precisão (0,513).** O **Gradient Boosting** registrou 160 VN (78,4%), 21 VP (10,3%), 17 FP (8,3%) e 6 FN (2,9%). **Com o menor número absoluto de FN, o Gradient Boosting identificou 21 dos 27 vinhos Alta no conjunto de teste, mantendo os alarmes falsos em apenas 17.**

O Gradient Boosting incorreu apenas 6 Falsos Negativos, ou seja, classificou erroneamente apenas 6 vinhos premium como comuns em 204 amostras testadas. **Essa é a métrica de maior impacto financeiro para uma vinícola, pois cada FN representa um produto premium que seria vendido com preço inferior ao seu valor real.**

4.3.3 Resultado Global: Acertos vs Erros

A Figura 9 sintetiza o número total de acertos e erros por modelo no conjunto de teste, oferecendo uma perspectiva direta e intuitiva sobre o desempenho global.




Figura 9: Previsões corretas vs incorretas por modelo no conjunto de teste

O gráfico confirma a progressão de desempenho esperada: a *Logistic Regression* cometeu 42 erros (20,6% das amostras), o *Random Forest* reduziu os erros para 26 (12,7%) e o *Gradient Boosting* atingiu o melhor resultado com apenas 23 erros (11,3%). **A redução de 42 para 23 erros ao longo da progressão de complexidade dos modelos representa uma diminuição de 45% na taxa de erro global**, validando a escolha de modelos *ensemble* sobre o baseline linear para este problema.

4.4 Importância das Features

4.4.1 Gini Importance versus Permutation Importance

A Figura 10 apresenta a importância das *features* calculada por dois métodos complementares para o *Random Forest* e o *Gradient Boosting*: *Gini Importance* (redução média de impureza nas divisões das árvores) e *Permutation Importance* (queda no *F1-Score* ao embaralhar aleatoriamente os valores de cada *feature*). Quando os dois métodos convergem para as mesmas *features* o resultado é considerado confiável.




Figura 10: *Feature Importance* por método Gini e Permutation

Para o *Random Forest*, a *Gini Importance* aponta *alcohol* (0,1551) e *alcohol_density* (0,1517) como as duas *features* mais importantes, seguidas por *sulphates_log* (0,1159), *volatile acidity* (0,1020) e *acid_ratio* (0,0811). A *Permutation Importance* manteve as mesmas cinco *features* no topo, porém com alteração na ordem: *sulphates_log* subiu para a primeira posição (0,0849), seguida de *alcohol_density* (0,0752) e *alcohol* (0,0522). **Essa convergência entre os dois métodos válida a robustez dos resultados.**

Para o *Gradient Boosting*, a *Gini Importance* é dominada pelo *alcohol* (0,3472), com impacto bem mais concentrado que no *Random Forest*, refletindo a natureza do *boosting* de focar nos exemplos mais difíceis. *Volatile acidity* (0,1091) e *sulphates_log* (0,1085) ficaram em segundo e terceiro lugar. Na *Permutation Importance* do *Gradient Boosting*, *sulphates_log* liderou (0,1855), seguido de *alcohol* (0,1553) e *residual_sugar_log* (0,0771), sugerindo que o *Gradient Boosting* explorou a variável *residual_sugar* de forma mais eficiente quando considerado o impacto real na métrica F1.

A *feature engineered alcohol_density* ocupou consistentemente posição de destaque no Random Forest por ambos os métodos, validando a decisão de criação dessa *feature*, a razão entre teor alcoólico e densidade captura a completude da fermentação de forma mais expressiva do que cada variável individualmente. Para o *Gradient Boosting*, *acid_ratio* também se destacou na *Permutation Importance*, confirmando o valor das *features engineered* criadas com conhecimento de domínio enológico.

5. Conclusão

5.1 Síntese dos Resultados

O pipeline desenvolvido demonstrou com solidez que é possível prever a qualidade de vinhos tintos com desempenho útil usando exclusivamente dados físico-químicos coletados durante a produção. A progressão *Logistic Regression*, *Random Forest* e *Gradient Boosting* confirmou que as relações entre as características químicas e a qualidade sensorial são essencialmente não-lineares, e que modelos de *ensemble* capturam esses padrões de forma muito mais eficiente do que abordagens lineares.

O desbalanceamento de 6,4:1 entre as classes foi tratado com rigor metodológico por meio do SMOTE aplicado dentro de um *ImbPipeline* de validação cruzada, garantindo que as métricas reportadas reflitam desempenho genuíno em dados não vistos. A escolha do *RobustScaler* para normalização foi validada pela presença de *outliers* sistemáticos nas *features* assimétricas, que distorceriam significativamente a escala do *StandardScaler* convencional. A *feature engineering* produziu resultados concretos: *alcohol_density*, criada como *proxy* de fermentação completa, foi a segunda *feature* mais importante no *Random Forest* por ambos os métodos de avaliação. *acid_ratio* destacou-se na *Permutation Importance* do *Gradient Boosting*.

5.2 Decisão sobre o Modelo Vencedor

A escolha entre *Random Forest* e *Gradient Boosting* depende da prioridade de negócio estabelecida pelo cliente ou gestor da vinícola.

***Gradient Boosting* e o modelo recomendado quando o objetivo é maximizar a identificação de vinhos *premium*, minimizando a perda de receita por subclassificação.** Com F1-Score de 0,646, Recall de 0,778 e apenas 6 Falsos Negativos no conjunto de teste, e o modelo mais equilibrado para o cenário em que errar para menos e o erro mais custoso.

***Random Forest* e o modelo recomendado quando a confiabilidade probabilística e a prioridade.** Com PR-AUC de 0,664, o modelo produz probabilidades mais bem calibradas para a classe Alta, sendo a escolha ideal para sistemas que precisam ajustar o limiar de decisão conforme o nível de confiança desejado pelo negócio.

Como recomendação, usar o *Gradient Boosting* como modelo principal de produção, com *Random Forest* como modelo de referência para calibração de probabilidades e ajuste de limiar.

Adicionalmente, foi realizada uma análise de **otimização do limiar de decisão** (*threshold tuning*) para o *Gradient Boosting*. Por padrão, o método *predict()* utiliza *threshold* de 0,50, mas com o desbalanceamento de 6:1 entre as classes, esse valor pode não ser ótimo. Ao variar o limiar de 0,10 a 0,90 e medir o F1-Score resultante, identificou-se que **o *threshold* ótimo é 0,55**, elevando o F1-Score de 0,646 para **0,667**, com *Precision* de 0,583 e Recall de 0,778. Esse limiar ligeiramente mais conservador reduz os alarmes falsos (Falsos Positivos) sem sacrificar significativamente a detecção de vinhos premium. **Recomenda-se o uso do *threshold* 0,55 em ambiente de produção** quando o objetivo for maximizar o F1-Score. Caso a prioridade seja minimizar a perda de vinhos premium (reduzir Falsos Negativos), um *threshold* ainda menor pode ser adotado, aumentando o Recall à custa de mais alarmes falsos.

5.3 Limitações e Próximos Passos

1. **Tamanho do *dataset*:** 1.018 amostras e um conjunto moderadamente pequeno. Mais dados, especialmente da classe Alta, poderiam melhorar os resultados de forma substancial.
2. **Representatividade:** o *dataset* cobre apenas vinho tinto português (Vinho Verde). A generalização para outros tipos de vinho, regiões e uvas exigiria retreinamento com dados representativos.
3. **Otimização de hiper parâmetros:** os modelos foram treinados com configurações razoáveis, mas sem busca sistemática por hiper parâmetros ótimos.
4. ***Threshold* de decisão calibrado:** o *threshold* ótimo de 0,55 foi identificado via análise de *tuning* e deve ser reavaliado caso o modelo seja retreinado com novos dados ou aplicado em contexto de negócio diferente. Para priorização de Recall (minimizar perda de vinhos premium), um limiar ainda menor pode ser adotado.
5. **Explicabilidade individual:** para uso em produção, técnicas como SHAP (*SHapley Additive exPlanations*) seriam recomendadas para comunicar ao enólogo as razões específicas de cada predição individual, aumentando a confiança do usuário final na ferramenta.

6. Aplicação Prática

6.1 Cenários de Uso na Indústria Vitivinícola

O modelo desenvolvido tem potencial de aplicação direta em diversas etapas do processo produtivo de uma vinícola moderna. Os três cenários principais identificados são descritos a seguir.

Controle de Qualidade em Linha de Produção

Sensores físico-químicos modernos podem coletar em tempo quase-real os dados de cada lote em fermentação: teor alcoólico, acidez, densidade e demais parâmetros. Integrado a esses sensores, o modelo pode emitir alertas antecipados sobre lotes com baixa probabilidade de atingir a classificação Alta, permitindo que o enólogo intervenha ainda durante a fermentação, ajustando temperatura, acidez ou dose de sulfatos, antes que o produto esteja terminado. O custo de uma intervenção preventiva é significativamente menor do que o custo do rejeito após avaliação sensorial.

Segmentação e Precificação de Produtos

O modelo pode ser usado para pré-classificar lotes antes da avaliação sensorial formal, direcionando os recursos de avaliação para os casos mais duvidosos (score probabilístico entre 0,40 e 0,60) e poupando tempo dos especialistas para os lotes claramente Alta (score acima de 0,75) ou Baixa/Média (score abaixo de 0,25). Essa triagem pode acelerar o ciclo de liberação de produto para o mercado e apoiar decisões de precificação com mais agilidade.

Formulação e Reprodução de Lotes *Premium*

A análise de importância das *features* revela os parâmetros físico-químicos que mais diferenciam vinhos de alta qualidade dos demais. Esse conhecimento pode ser usado como guia na formulação de novos lotes.

Quais são os valores de *alcohol*, *volatile acidity*, *sulphates* e *acid_ratio* mais associados com a classe de vinhos de Alta qualidade com base nos dados históricos. O modelo transforma empirismo tácito em especificações quantitativas, facilitando a reprodutibilidade de safras premiadas.

6.2 Impacto Potencial e Retorno sobre Investimento

Dimensão	Problema Atual	Benefício com o Modelo
Redução de rejeição	Lotes fora do padrão só são identificados após avaliação sensorial	Antecipação e redução de custo de rejeição
Eficiência do especialista	Todo lote passa por avaliação completa (tempo e custo elevados)	Triagem automática concentra especialistas nos casos incertos
Padronização de qualidade	Variabilidade entre safras e entre avaliadores	Feedback quantitativo guia ajustes no processo produtivo
Receita de produtos premium	Risco de subclassificar vinhos Alta por falta de dados	Recall de 77,8% já reduz substancialmente esse risco

6.3 Roadmap de Implementação

1. **Validação com dados da vinícola:** O modelo atual foi treinado com o *dataset WineQT*. Antes de ser colocado em produção, é essencial verificar se o desempenho se mantém com os dados específicos da vinícola. Caso haja diferenças significativas, deve-se realizar o retreinamento para garantir maior aderência à realidade local.
2. **Integração com coleta de dados:** Configurar um sistema automatizado para coletar os parâmetros físico-químicos durante a fermentação. Idealmente, essa coleta deve ser temporal, permitindo acompanhar a evolução de cada lote ao longo do processo.
3. **Interface operacional:** Desenvolver um dashboard simples e intuitivo que apresente o score de probabilidade de alta qualidade por lote.
4. **Monitoramento de drift:** Modelos em produção podem perder desempenho ao longo do tempo se as características dos vinhos mudarem. Por isso, é importante implementar mecanismos de monitoramento de data *drift*.
5. **Ciclo de feedback com especialistas:** Incorporar as avaliações sensoriais reais dos lotes ao longo do tempo, enriquecendo o *dataset* com informações mais recentes e relevantes.

6.4 Salvaguardas no Uso de Modelos Preditivos

Modelos preditivos devem ser vistos como **apoio à decisão**, nunca como substitutos do especialista humano. Decisões comerciais críticas, como **precificação premium** ou **rejeição de lotes**, precisam sempre de validação humana, especialmente quando o score do modelo está próximo ao limiar.

A **transparência** sobre limitações é essencial: comunicar taxas de erro e restrições de generalização ajuda os usuários a calibrar sua confiança.

Também é fundamental garantir a **rastreabilidade das previsões**, registrando versão do modelo, variáveis de entrada e score probabilístico. Isso permite auditorias futuras e sustenta a melhoria contínua do sistema.

Referencias

- CORTEZ, P. et al. *Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems*, v. 47, n. 4, p. 547-553, 2009.
- CHAWLA, N. V. et al. SMOTE: *Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research*, v. 16, p. 321-357, 2002.
- PEDREGOSA, F. et al. *Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.
- FRIEDMAN, J. H. *Greedy function approximation: A gradient boosting machine. Annals of Statistics*, v. 29, n. 5, p. 1189-1232, 2001.
- SINGH, R.; TIWARI, A. *The Wine Quality Dataset*. Kaggle. Disponível em: <https://www.kaggle.com/datasets/rajyellow46/wine-quality>. Acesso em: Jun. 2025.